

Ringkasan Proyek NLP

LDA Topic Modeling, FTC Clustering, dan Rule-Based NER pada 500 komentar YouTube

Komponen	Ringkasan
Dataset	500 komentar dari komentar_youtube.csv; kolom teks: komentar.
LDA	5 topic untuk membaca tema besar komentar.
FTC Clustering	42 cluster, termasuk 1 residual berisi 80 komentar.
Rule-Based NER	568 entitas dari aturan regex/kamus; label terbanyak: PER.

Perubahan utama: clustering tidak lagi memakai KMeans, tetapi memakai pendekatan FTC seperti materi kuliah. NER juga tidak lagi memakai IndoBERT, melainkan aturan eksplisit berbasis regex dan kamus domain.

Alur Proyek Baru

Tahap	Metode	Output
Preprocessing	Tokenisasi, stopword, slang map	comments_preprocessed.csv
Topic Modeling	LDA	topic_words.csv, topic_matrix.csv
Clustering	FTC + Entropy Overlap	cluster_summary.csv, ftc_selected_clusters.csv
NER	Rule-based regex/kamus	ner_entities_rule_based_komentar_youtube.csv

Hasil LDA Topic Modeling

Topic	Jumlah	Confidence	Top terms	Interpretasi
0	116	0.5773	orang, tumbal, nadim, pak, tau, sdh, penjara, masuk, mulyono, koruptor	Figur Nadiem/Nadim dan respons publik
1	107	0.6690	pak, nadiem, allah, semoga, tidak, tuhan, siapa, hakim, sabar, korupsi	Figur Nadiem/Nadim dan respons publik
2	96	0.6879	jokowi, hukum, politik, menteri, gila, korban, negara, menjadi, tidak, jahat	Kritik hukum dan negara
3	107	0.7073	indonesia, hukum, negara, tidak, rakyat, jangan, anak, uang, korupsi, konoha	Kritik hukum dan negara
4	74	0.7008	jokowi, tidak, orang, pasti, nadiem, bapak, punya, dunia, bang, menteri	Figur Nadiem/Nadim dan respons publik

Catatan: LDA memberi tema, sedangkan FTC menentukan cluster berdasarkan frequent term-set dari dokumen.

Hasil FTC Clustering

Tabel ini menampilkan cluster terbesar. Residual adalah dokumen yang tidak lagi memenuhi minimum support kandidat frequent term-set.

Cluster	Jumlah	FTC term-set	EO	Top terms cluster
41	80	RESIDUAL_UNASSIGNED	0.0000	indonesia, tolol, mundur, edan, ojol, jokodok, menjadi, siap, ngeri, pengadilan
36	30	jokowi	1.3863	jokowi, pasti, hidup, minta, takut, prabowo, indonesia, kenapa, harus, jawab
30	16	semoga	2.3287	semoga, nadiem, allah, pak, lebih, karma, amien, tidak, kebenaran, terungkap
38	15	tidak	2.1187	tidak, negara, manusia, hukum, generasi, pernah, mati, masuk, bermanfaat, hukumnya
35	13	nadiem	2.4456	nadiem, jokowi, tidak, tuhan, pendukung, kena, ketidak, dulu, pip, skrg
23	13	koruptor	2.4013	koruptor, jelas, biar, kapok, hukum, negara, tidak, orang, tuntutan, harus
40	13	hukum	1.3863	hukum, indonesia, penegak, hakim, ngeri, sungguh, mengerikan, dinegri, smg, jaksa
25	12	jangan	2.3876	jangan, kalau, negara, bayar, menolong, setengah, korupsi, makanya, dong, tidak
32	12	pak	2.1187	pak, nadim, sabar, allah, bersama, bpk, semangat, hakim, zolim, insaallah
29	12	siapa	2.4653	siapa, semoga, tuhan, aamiin, pak, zolim, suruh, hal, sebenarnya, bpk
37	12	orang	2.8119	orang, tidak, negara, indonesia, jabatan, mukidi, lucu, bahan, pangan, diam
22	11	korban	2.0744	korban, jokowi, nadiem, menteri, keganasan, yaqut, nyebut, koruptor, tertangkap, mentang...

Detail Iterasi FTC

Iterasi	Cluster	Frequent term-set	Support	EO	Sisa dokumen
1	0	hakim, tidak	8	1.8990	492
2	1	nadiem, orang	8	1.9106	484
3	2	vonis	8	2.0315	476
4	3	sekarang	8	2.0359	468
5	4	pak, tidak	8	2.0495	460
6	5	mas	8	2.2237	452
7	6	jahat	9	2.1279	443
8	7	klo	8	2.1967	435
9	8	parah	8	1.9877	427
10	9	gila	9	2.0124	418
11	10	penjara	9	2.1633	409
12	11	politik	8	2.0940	401
13	12	dunia	10	2.1449	391
14	13	konoha	11	2.2060	380
15	14	sdh	8	2.3281	372
16	15	rakyat	9	2.0264	363
17	16	maling	8	2.0708	355
18	17	pejabat	8	2.1187	347

Tabel iterasi menunjukkan urutan pemilihan cluster FTC dari EO minimum.

Hasil Rule-Based NER

Label	Jumlah	Makna singkat
PER	221	Person/tokoh
LAW	176	Istilah hukum
REG	82	Agama/kepercayaan
GPE	39	Wilayah/geopolitik
ORG	31	Organisasi/kelompok
MON	10	Uang/nominal
QTY	6	Kuantitas
EVT	3	Event/peristiwa

Contoh Entity Rule-Based NER

Entity	Label	Rule	Potongan komentar
jokodok	PER	person_jokowi	Perlawanan ojol dgn tolak jokodok
ojol	ORG	org_gojek	Perlawanan ojol dgn tolak jokodok
Nadiem	PER	person_nadiem	Pilpres yg untuk menentukan nasib 280 juta orang Indonesia saja bisa diatur, apalagi cuma untuk 1 orang Indonesia ... ?! Y...
Indonesia	GPE	geo_indonesia	Pilpres yg untuk menentukan nasib 280 juta orang Indonesia saja bisa diatur, apalagi cuma untuk 1 orang Indonesia ... ?! Y...
Indonesia	GPE	geo_indonesia	Pilpres yg untuk menentukan nasib 280 juta orang Indonesia saja bisa diatur, apalagi cuma untuk 1 orang Indonesia ... ?! Y...
Pilpres	EVT	event_terms	Pilpres yg untuk menentukan nasib 280 juta orang Indonesia saja bisa diatur, apalagi cuma untuk 1 orang Indonesia ... ?! Y...
280 juta	MON	money_terms	Pilpres yg untuk menentukan nasib 280 juta orang Indonesia saja bisa diatur, apalagi cuma untuk 1 orang Indonesia ... ?! Y...
1 orang	QTY	quantity_terms	Pilpres yg untuk menentukan nasib 280 juta orang Indonesia saja bisa diatur, apalagi cuma untuk 1 orang Indonesia ... ?! Y...
Indonesia	GPE	geo_indonesia	Yg membuka lapangan kerja ber juta orang di Indonesia di bui, sedangkan koruptor di Indonesia yg merajalela, semakin solid,(...
Indonesia	GPE	geo_indonesia	Yg membuka lapangan kerja ber juta orang di Indonesia di bui, sedangkan koruptor di Indonesia yg merajalela, semakin solid,(...
indonesia	GPE	geo_indonesia	Yg membuka lapangan kerja ber juta orang di Indonesia di bui, sedangkan koruptor di Indonesia yg merajalela, semakin solid,(...
koruptor	LAW	legal_terms	Yg membuka lapangan kerja ber juta orang di Indonesia di bui, sedangkan koruptor di Indonesia yg merajalela, semakin solid,(...

Kesimpulan Utama

Poin	Penjelasan
LDA	Topic terbesar adalah Topic 0 dengan 116 komentar.
FTC	FTC menghasilkan 42 cluster. Cluster tematik terbesar adalah cluster 36 dengan 30 komentar; residual berisi 80 komentar.
NER	Rule-based NER menemukan 568 entitas; label paling banyak adalah PER sebanyak 221 entitas.
Kelebihan	Metode sesuai materi FTC dan NER rule-based lebih transparan karena aturan dapat dibaca langsung.
Batasan	FTC sensitif pada min_support dan rule-based NER terbatas pada pola/kamus yang ditulis.
Saran lanjut	Uji beberapa min_support FTC dan perluas kamus NER untuk nama tokoh, lembaga, lokasi, serta istilah hukum.